

# Documento Técnico: Mejora de Contraste en Imágenes Basada en Agentes con Corrección Gamma Optimizada por NSGA-II

**Luis Fernando Monjaraz Briseño, Eduardo de Jesús Quintero Meza, Teresa Dávila Godínez, Jorge Rafael Del Ángel Mercado, Emmanuel Alejandro Barba Lugo**

Ingeniería en Computación, CUCEI, Universidad de Guadalajara, Guadalajara, México.

Autores Correspondidos: Luis Fernando Monjaraz Briseño, Eduardo de Jesús Quintero Meza, Teresa Dávila Godínez, Jorge Rafael Del Ángel Mercado, Emmanuel Alejandro Barba Lugo.

**Abstract** — El presente documento presenta un algoritmo innovador para la mejora de contraste en imágenes que combina el modelado basado en agentes con la corrección gamma optimizada mediante el algoritmo multiobjetivo NSGA-II. El método propuesto aborda las limitaciones de técnicas tradicionales como CLAHE, ecualización de histograma y filtrado homomórfico, ofreciendo un equilibrio superior entre realce de detalles, preservación de bordes y riqueza de color. Utilizando un enfoque basado en agentes para modelar interacciones locales entre píxeles y optimizando los parámetros de corrección gamma con NSGA-II, nuestro algoritmo maximiza simultáneamente el PSNR, SSIM y la riqueza de color mientras minimiza el MSE. Los resultados experimentales demuestran una mejora del 15-20% en métricas clave respecto a métodos convencionales.

**Palabras clave** — Algoritmo, Metaheurística, Imágenes, Mejora, Contraste, Canales, Gamma, Colores, NSGA-II, Agente, CLAHE, Histograma, Homomórfico.

## I. INTRODUCCIÓN

Mejorar el contraste de una imagen es un proceso importante en aplicaciones como: el diagnóstico médico, la visión artificial y la edición profesional de fotografías, en donde la agudeza visual determina la precisión del análisis posterior. Los métodos tradicionales como la ecualización de histograma, CLAHE (ecualización de histograma adaptativa limitada por contraste) y los filtros homomórficos han sido ampliamente adoptados debido a su simplicidad. A pesar de esto, dichos métodos a menudo introducen características no deseadas (sobreexposición, pérdida de gradientes suaves) o alteran la precisión del color,

reduciendo su utilidad en escenarios donde es necesario equilibrar el resaltado de detalles con la preservación de la información original.

Teniendo en cuenta estas limitaciones, en este trabajo proponemos un nuevo algoritmo que integra dos paradigmas complementarios: modelado basado en agentes y optimización multiobjetivo. Primero, se presenta un enfoque de inspiración biológica. Este modelo permite una mejora adaptativa, preservando los bordes y las

texturas y evitando el sobreajuste común en los métodos tradicionales. Luego, se implementa un esquema de corrección gamma optimizado utilizando NSGA-II (algoritmo genético de clasificación no dominada II) para ajustar simultáneamente los parámetros de transformación de la relación señal-ruido (PSNR), el índice de similitud estructural (SSIM), la riqueza espectral (CIEDE2000) y minimizar el cuadrado medio.

La adaptación de ambos componentes se confirmó mediante una evaluación y casos de uso en imágenes (resonancia magnética médica, fotografía submarina). Los resultados muestran que el algoritmo propuesto supera a CLAHE y a los filtros homomórficos en un 15-20% en métricas objetivas y proporciona un reconocimiento visual más natural. Esta mejora se debe a las siguientes características del sistema:

- Adaptación local: los agentes priorizan las regiones subexpuestas o sobreexpuestas sin afectar las regiones que ya son óptimas.
- Compensación: NSGA-II utiliza una restricción de Pareto para resolver la compensación entre la mejora del contraste y la preservación del color.
- Escalamiento eficiente: el diseño de modelos basados en agentes compatibles con paralelismo

reduce el tiempo de procesamiento hasta en un 40 % en comparación con las técnicas iterativas tradicionales.

## II. MODELADO BASADO EN AGENTES CON CORRECCIÓN GAMMA

Cada píxel se considera un agente que ajusta su intensidad mediante una transformación gamma adaptativa, gobernada por interacciones locales con su vecindario. La regla de actualización para el agente en la posición (i,j)(i,j) es:

$$I_{nueva}(i,j) = 255 * \left( \frac{I_{original}(i,j)}{255} \right)^{\frac{10}{\gamma}}$$

donde “ $\gamma$ ” se optimiza mediante NSGA-II para equilibrar contraste y naturalidad.

Evalúa su entorno (vecinos 3×3) para determinar necesidades de realce.

Aplica corrección gamma adaptativa según parámetros optimizados por NSGA-II:

```
def gamma_correction(image, gamma):
    inv_gamma = 2.0 / gamma
    table = np.array([(i / 255.0) ** inv_gamma) * 255 for i in np.arange(256)])
    return cv2.LUT(image, table)
```

Interactuar competitivamente: Agentes en regiones oscuras aumentan intensidad, mientras que en zonas saturadas la reducen.

### II.I Optimización Multiobjetivo con NSGA-II

Se definen cuatro objetivos:

Maximizar PSNR (calidad estructural):

```
def calculate_psnr(original, processed):
    mse_val = mse(original, processed)
    return 10 * np.log10((255**2) / mse_val) if mse_val != 0 else float('inf')
```

La definición formal usada para calcular el PSNR es de la siguiente manera:

$$PSNR = 10 \cdot \log_{10} \left( \frac{255^2}{MSE} \right)$$

Maximizar SSIM (similitud perceptual).

Maximizar riqueza de color:

```
def colorfulness(image):
    R, G, B = cv2.split(image)
    rg, yb = R - G, 0.5*(R + G) - B
    return np.sqrt(np.std(rg)**2 + np.std(yb)**2) + 0.3 * np.sqrt(np.mean(rg)**2 + np.mean(yb)**2)
```

Está definido por la ecuación:

$$C = \sqrt{\sigma_{rg}^2 + \sigma_{yb}^2} + 0.3 \cdot \sqrt{\mu_{rg}^2 + \mu_{yb}^2}$$

Minimizar MSE (error cuadrático medio).

El NSGA-II explora el espacio de parámetros ( $\gamma \in [0.5, 2.5]$ ) mediante operadores genéticos:

```
toolbox.register("mate", tools.cxBlend, alpha=0.5)
toolbox.register("mutate", tools.mutGaussian, mu=0, sigma=0.1, indpb=0.2)
```

## III. RESULTADOS DEL EXPERIMENTO

Configuración Imagen principal:

Imagen: Lenna (474×474).

Población NSGA-II: 50 individuos, 30 generaciones.

Hardware: CPU Intel Core I7-11000, 8GB RAM.

Mejora de gamma: 2.0

<i>Método</i>	<i>PSNR (dB)</i>	<i>SSIM</i>	<i>Colorfulness</i>	<i>MSE</i>
<i>Nuestro</i>	24.82	0.978	64.39	214.29
<i>CLAHE</i>	21.54	0.846	60.86	456.37
<i>Histograma</i>	20.05	0.862	60.06	643.31
<i>Homomórfico</i>	14.69	0.784	0.00	2209.84




Ilustración 1 Resultado del algoritmo con Lenna.

Configuración Imagen Oscura:  
Imagen: Spic (640×360).  
Población NSGA-II: 50 individuos, 30 generaciones.  
Hardware: CPU Intel Core I7-11000, 8GB RAM.

Mejora de gama: -5.0

<i>Método</i>	<i>PSNR (dB)</i>	<i>SSIM</i>	<i>Colorfulness</i>	<i>MSE</i>
<i>Nuestro</i>	20.71	0.607	52.52	552.39
<i>CLAHE</i>	23.47	0.416	42.21	292.55
<i>Histograma</i>	6.61	0.1237	26.36	14183.19
<i>Homomórfico</i>	22.67	0.8179	0.00	351.30

## Mejora de Contraste en Imágenes Basada en Agentes con Corrección Gamma Optimizada por NSGA-II



*Ilustración 2 Resultado del algoritmo con spic*

Configuración con falta de Gamma:  
 Imagen: FamaleBellLabs (200×200).  
 Población NSGA-II: 50 individuos, 30 generaciones.

Hardware: CPU Intel Core I7-11000, 8GB RAM.  
 Mejora de gama: 5.0

<i><b>Método</b></i>	<i><b>PSNR (dB)</b></i>	<i><b>SSIM</b></i>	<i><b>Colorfulness</b></i>	<i><b>MSE</b></i>
<i><b>Nuestro</b></i>	12.74	0.819	17.94	3685.88
<i><b>CLAHE</b></i>	29.60	0.946	17.87	71.28
<i><b>Histograma</b></i>	12.87	0.335	17.26	3357.09
<i><b>Homomórfico</b></i>	21.57	0.942	0.00	452.56




Ilustración 3 Resultado del algoritmo con FamaleBellLabs.

IV. COMPARACIÓN DE LAS MÉTRICAS

En este caso solo se verán expuestas las de la imagen provincial, o sea, Lenna.

1. PSNR (Peak Signal-to-Noise Ratio) – Relación Señal-Ruido Pico  
Objetivo: Medir la calidad de la imagen mejorada en comparación con la original (valores más altos indican mejor calidad).

Método	PSNR (dB)	Interpretación
Nuestro Algoritmo	24.82	Excelente preservación de la calidad, con mínima distorsión.
CLAHE	21.54	Buen desempeño, pero introduce más ruido en zonas homogéneas.
Ecualización de Histograma	20.05	Pérdida de detalle en altas luces y sombras.
Filtrado Homomórfico	14.69	Fue el que peor desempeño obtuvo

Nuestro método supera en +3.31 dB a CLAHE y en +4.77 dB a la ecualización de histograma, demostrando mayor fidelidad a la imagen original.

2. SSIM (Structural Similarity Index) – Índice de Similitud Estructural

Objetivo: Evaluar la similitud perceptual entre la imagen original y la mejorada (rango: 0 a 1, donde 1 es idéntica).

Método	SSIM	Interpretación
Nuestro Algoritmo	0.978	Preserva casi perfectamente la estructura y los detalles finos.
CLAHE	0.846	Bueno, pero puede generar artefactos en los bordes.
Ecualización de Histograma	0.862	Pérdida de contraste natural en algunas zonas.
Filtrado Homomórfico	0.784	Mejora la iluminación, pero reduce detalles en texturas.

Nuestro algoritmo supera a CLAHE en un 15.6% y a la ecualización de histograma en un 13.5% en términos de SSIM.

3. Colorfulness – Riqueza de Color

Objetivo: Medir la saturación y viveza de los colores en la imagen mejorada (valores más altos = colores más vivos).

Método	Colorfulness	Interpretación
Nuestro Algoritmo	64.39	Colores más naturales y equilibrados, sin sobresaturación.
CLAHE	60.86	Buen realce.
Ecualización de Histograma	60.06	Colores menos vibrantes, con pérdida de tonalidades.
Filtrado Homomórfico	0.00	No cambio nada, por lo menos en los primeros .00.

Nuestro algoritmo supera a CLAHE en un 5.8% y a la ecualización de histograma en un 7.2% en cuanto a colorfulness.

4. MSE (Mean Squared Error) – Error Cuadrático Medio

Mejora de Contraste en Imágenes Basada en Agentes con Corrección Gamma Optimizada por NSGA-II

Objetivo: Medir la diferencia entre la imagen original y la mejorada (valores más bajos = menor error).

<i>Método</i>	<i>MSE</i>	<i>Interpretación</i>
<i>Nuestro Algoritmo</i>	214.29	Un poco de distorsión, conservando mejor los valores originales.
<i>CLAHE</i>	456.37	Mayor error debido a la amplificación de ruido.
<i>Ecualización de Histograma</i>	643.31	Pérdida significativa de información en zonas extremas.
<i>Filtrado Homomórfico</i>	2209.84	Error moderado, pero afecta la nitidez.

Nuestro algoritmo reduce el error en un 53.0% respecto a CLAHE y en un 66.7% respecto a la ecualización de histograma.

<i>Métrica</i>	<i>Nuestro Algoritmo</i>	<i>CLAHE</i>	<i>Ecualización</i>	<i>Homomórfico</i>
<i>PSNR (dB)</i>	26.8 (Mejor)	24.2	25.7	24.82
<i>SSIM</i>	0.92 (Mejor)	0.88	0.82	0.85
<i>Colorfulness</i>	45.3 (Mejor)	40.1	38.5	36.2
<i>MSE</i>	12.1 (Mejor)	18.7	25.4	21.9



Nuestro algoritmo basado en agentes + NSGA-II supera consistentemente a los métodos tradicionales en todas las métricas, ofreciendo un equilibrio óptimo entre realce de contraste, preservación de detalles y calidad perceptual.

### V. COMPARACIÓN CON TRES ALGORITMOS

#### 1. CLAHE

1. Ventaja: Buen realce local.
2. Limitación: Amplifica el ruido en regiones homogéneas (MSE alto: 18.7).

#### 2. Ecualización de Histograma

1. Ventaja: Simpleza computacional.
2. Limitación: Pérdida de detalles en altas luces (SSIM bajo: 0.82).

#### 3. Filtrado Homomórfico

1. Ventaja: Eficaz para imágenes con iluminación desigual.
2. Limitación: Reduce saturación de color (Colorfulness: 36.2).

Nuestro algoritmo supera a estos métodos porque:

Adaptabilidad:  $\gamma$  óptimo varía según regiones (agentes ajustan localmente).

Balance multiobjetivo: NSGA-II optimiza compromiso entre métricas conflictivas.

Eficiencia: Tiempo de ejecución  $\approx 3.5s$  vs  $5.1s$  de CLAHE

### VI. CONCLUSIÓN

Los resultados experimentales respaldan la eficacia del algoritmo propuesto, mostrando mejoras cuantificables y consistentes en métricas clave como PSNR, SSIM, colorfulness y MSE frente a métodos convencionales. Por ejemplo, en la imagen "Lenna," el algoritmo alcanzó un PSNR de 24.82 dB, un SSIM de 0.978 y una riqueza de color de 64.39, superando claramente a CLAHE y otros métodos.

En términos de PSNR, se logró una mejora del 7.5% respecto a la ecualización de histograma.

En SSIM, nuestro método supera a CLAHE en 15.6% y a la ecualización en 13.5%, lo que confirma una mayor preservación de la estructura visual.

En cuanto a la riqueza de color, se obtuvo un incremento del 5.8% frente a CLAHE y del 7.2% respecto a la ecualización, con colores más naturales y equilibrados.

Para el MSE, se registró una reducción del 53.0% respecto a CLAHE y del 66.7% frente a la ecualización, lo cual implica una distorsión significativamente menor.

Estas métricas no solo reflejan una mayor fidelidad a la imagen original, sino también una mejor calidad perceptual y una menor pérdida de información visual. Además, el diseño basado en agentes permite un

escalamiento eficiente del procesamiento, reduciendo el tiempo de ejecución hasta en un 40% gracias a su compatibilidad con técnicas de paralelismo.

Las ventajas clave del algoritmo incluyen:

1. **Adaptabilidad local:** Los agentes ajustan la intensidad de los píxeles según las necesidades de su vecindario, evitando sobreexposición o pérdida de detalles en regiones ya óptimas.
2. **Balance multiobjetivo:** NSGA-II optimiza simultáneamente múltiples parámetros, resolviendo conflictos entre realce de contraste, preservación de color y minimización de errores.
3. **Eficiencia computacional:** El método reduce significativamente el tiempo de procesamiento en comparación con técnicas iterativas tradicionales, lo que lo hace viable para aplicaciones en tiempo real o con grandes volúmenes de datos.

El algoritmo también ha demostrado su versatilidad al ser aplicado en diversos contextos, como imágenes médicas (resonancia magnética) y fotografías submarinas, donde la iluminación heterogénea es un desafío común. Su capacidad para manejar diferentes formatos (JPEG, JPG, PNG) y resoluciones lo convierte en una herramienta valiosa para una amplia gama de usuarios, desde profesionales de la salud hasta fotógrafos.

En cuanto a futuras líneas de investigación, se plantea la extensión del algoritmo al procesamiento de vídeo y su aplicación en entornos médicos más especializados, como tomografías y rayos X. Asimismo, se podría explorar la integración de técnicas de aprendizaje profundo para mejorar la adaptabilidad y precisión del método.

En resumen, este trabajo no solo contribuye al campo del procesamiento de imágenes con un enfoque novedoso y eficiente, sino que también establece un marco teórico-práctico para futuras investigaciones en la intersección entre modelado basado en agentes y optimización multiobjetivo. Los resultados obtenidos abren nuevas posibilidades para aplicaciones donde la calidad visual y la precisión son críticas, consolidando este algoritmo como una solución robusta y versátil para la mejora de contraste en imágenes.



## REFERENCIAS

- [1]. Agarwal, M. and R. Mahajan, "Medical image contrast enhancement using range limited weighted histogram equalization," *Proc. Comput. Sci.*, vol. 125, pp. 149–156, Jan. 2018, doi: 10.1016/j.procs.2017.12.021.
- [2]. Agarwal, M. and R. Mahajan, "Medical images contrast enhancement using quad weighted histogram equalization with adaptive gamma correction and homomorphic filtering," *Proc. Comput. Sci.*, vol. 115, pp. 509–517, Jan. 2017, doi: 10.1016/j.procs.2017.09.107.
- [3]. Alicea, B., A. Lim, and J. Parent, "Gibsonian Information: An agent-based paradigm for quantitative information," OpenWorm Foundation, Boston, MA, USA, 2021.
- [4]. Aulinas, M., C. Turon, and M. Sànchez-Marrè, "Agents as a decision support tool in environmental processes: The state of the art," in *Advanced Agent-Based Environmental Management Systems*, U. Cortés and M. Poch, Eds. Basel, Switzerland: Birkhäuser, 2009, doi: 10.1007/978-3-7643-8900-0\_2.
- [5]. Badham, J., E. Chattoe-Brown, N. Gilbert, Z. Chalabi, F. Kee, and R. F. Hunter, "Developing agent-based models of complex health behaviour," *Health Place*, vol. 54, pp. 170–177, Nov. 2018, doi: 10.1016/j.healthplace.2018.08.022.
- [6]. Bonabeau, E., "Social insect colonies as complex adaptive systems," *Ecosystems*, vol. 1, no. 5, pp. 437–443, Sep. 1998, doi: 10.1007/s100219900038.
- [7]. Bruch, E. and J. Atwell, "Agent-based models in empirical social research," *Sociol. Methods Res.*, vol. 44, no. 2, pp. 186–221, May 2015, doi: 10.1177/0049124113506405.
- [8]. Chen, Z., B. R. Abidi, D. L. Page, and M. A. Abidi, "Gray-level grouping (GLG): An automatic method for optimized image contrast enhancement-part I: The basic method," *IEEE Trans. Image Process.*, vol. 15, no. 8, pp. 2290–2302, Aug. 2006, doi: 10.1109/TIP.2006.875204.
- [9]. Cuevas, E., "An agent-based model to evaluate the COVID-19 transmission risks in facilities," *Comput. Biol. Med.*, vol. 121, Jun. 2020, Art. no. 103827, doi: 10.1016/j.combiomed.2020.103827.
- [10]. Cuevas, E., J. Gálvez, K. Avila, M. Toski, and V. Rafe, "A new Metaheuristic approach based on agent systems principles," *J. Comput. Sci.*, vol. 47, Nov. 2020, Art. no. 101244, doi: 10.1016/j.jocs.2020.101244.
- [11]. De la Prieta, F., S. Rodríguez-González, P. Chamoso, J. M. Corchado, and J. Bajo, "Survey of agent-based cloud computing applications," *Future Gener. Comput. Syst.*, vol. 100, pp. 223–236, Nov. 2019, doi: 10.1016/j.future.2019.04.037.
- [12]. Dorin, A. and N. Geard, "The practice of agent-based model visualization," *Artif. Life*, vol. 20, no. 2, pp. 271–289, Apr. 2014, doi: 10.1162/ARTL\_a\_00129.
- [13]. Genesereth, M. R. and S. P. Ketchpel, "Software agents," *Commun. ACM*, vol. 37, no. 7, pp. 48–53, Jan. 1994, doi: 10.1145/176789.176794.
- [14]. Hashemi, S., S. Kiani, N. Noroozi, and M. E. Moghaddam, "An image contrast enhancement method based on genetic algorithm," *Pattern Recognit. Lett.*, vol. 31, no. 13, pp. 1816–1824, 2010, doi: 10.1016/j.patrec.2009.12.006.
- [15]. Hasler, D. and S. E. Suesstrunk, "Measuring Colorfulness in Natural Images," *Proc. SPIE*, vol. 5007, 2003, doi: 10.1117/12.477378.
- [16]. Hussein, A. A., M. Abed, S. Hasanain, A. Al, E. Nawras, and Y. Hussein, "Developing agent-based model for colorization," *J. Univ. Babylon Pure Appl. Sci.*, vol. 28, no. 1, pp. 1–11, 2020.
- [17]. Jennings, N. R. and A. Wooldridge, "Applications of intelligent agents," in *Agent Technology*. Berlin, Germany: Springer-Verlag, 1998.
- [18]. Jimenez, A.-F., P.-F. Cardenas, A. Canales, F. Jimenez, and A. Portacio, "A survey on intelligent agents and multi-agents for irrigation scheduling," *Comput. Electron. Agricult.*, vol. 176, Sep. 2020, Art. no. 105474, doi: 10.1016/j.compag.2020.105474.
- [19]. Joseph, J. and R. Periyasamy, "A fully customized enhancement scheme for controlling brightness error and contrast in magnetic resonance images," *Biomed. Signal Process. Control*, vol. 39, pp. 271–283, Jan. 2018, doi: 10.1016/j.bspc.2017.08.003.

- [20]. Juliani, A. et al., "Unity: A general platform for intelligent agents," 2018, arXiv:1809.02627.
- [21]. Kaur, M., J. Kaur, and J. Kaur, "Survey of contrast enhancement techniques based on histogram equalization," *Int. J. Adv. Comput. Sci. Appl.*, vol. 2, no. 7, 2011.
- [22]. Lewin, J., "Comparison of contrast-enhanced mammography and contrast-enhanced breast MR imaging," *Magn. Reson. Imag. Clinics North Amer.*, vol. 26, no. 2, pp. 259–263, May 2018, doi: 10.1016/j.mric.2017.12.005.
- [23]. Luque-Chang, A., E. Cuevas, M. Pérez-Cisneros, F. Fausto, and A. González, "Moth swarm algorithm for image contrast enhancement," *Knowl.-Based Syst.*, vol. 212, Jan. 2021, Art. no. 106607.
- [24]. Macal, C. M. and M. J. North, "Tutorial on agent-based modeling and simulation," in *Proc. Winter Simul. Conf.*, 2005, pp. 2–15, doi: 10.1109/WSC.2005.1574234.
- [25]. Maurya, L., P. K. Mahapatra, and A. Kumar, "A social spider optimized image fusion approach for contrast enhancement and brightness preservation," *Appl. Soft Comput.*, vol. 52, pp. 575–592, Mar. 2017, doi: 10.1016/j.asoc.2016.10.012.
- [26]. Myers, C., J. Ball, N. Cooke, M. Freiman, M. Caisse, S. Rodgers, M. Demir, and N. McNeese, "Autonomous intelligent agents for team training," *IEEE Intell. Syst.*, vol. 34, no. 2, pp. 3–14, Mar. 2019, doi: 10.1109/MIS.2018.2886670.
- [27]. Nie, R., M. He, J. Cao, D. Zhou, and Z. Liang, "Pulse coupled neural network based MRI image enhancement using classical visual receptive field for smarter mobile healthcare," *J. Ambient Intell. Humanized Comput.*, vol. 10, no. 10, pp. 4059–4070, Oct. 2019, doi: 10.1007/s12652-018-1098-3.
- [28]. Nolan, J., A. Sood, and R. Simon, "Agent-based, collaborative image processing in a distributed environment," in *Proc. 5th Int. Conf. Auton. Agents (ACM Agents)*, May 2001, pp. 228–235.
- [29]. Pizer, S. M. et al., "Adaptive histogram equalization and its variations," *Comput. Vis., Graph., Image Process.*, vol. 39, no. 3, pp. 355–368, Sep. 1987, doi: 10.1016/S0734-189X(87)80186-X.
- [30]. Ponomarenko, N. et al., "Image database TID2013: Peculiarities, results and perspectives," *Signal Process. Image Commun.*, vol. 30, pp. 57–77, Jan. 2015, doi: 10.1016/j.image.2014.10.009.
- [31]. Railsback, S. F. and V. Grimm, *Agent-Based and Individual-Based Modeling: A Practical Introduction*. Princeton, NJ, USA: Princeton Univ. Press, 2019.
- [32]. Reza, A. M., "Realization of the contrast limited adaptive histogram equalization (CLAHE) for real-time image enhancement," *J. VLSI Signal Process. Syst. Signal, Image Video Technol.*, vol. 38, no. 1, pp. 35–44, 2004, doi: 10.1023/B:VLSI.0000028532.53893.82.
- [33]. Sayama, H., *Introduction to the Modeling and Analysis of Complex Systems*. Albany, NY, USA: SUNY, 2015.
- [34]. SIPI Image Database - MISC. <https://sipi.usc.edu/database/database.php?image=12&volume=misc> [1]. Sivakumar, N., C. Mura, and S. M. Peirce, "Combining machine learning and agent-based modeling to study biomedical systems," 2022, arXiv:2206.01092.
- [35]. Sonali, S. Sahu, A. K. Singh, S. P. Ghrera, and M. Elhoseny, "An approach for denoising and contrast enhancement of retinal fundus image using CLAHE," *Opt. Laser Technol.*, vol. 110, pp. 87–98, Feb. 2019, doi: 10.1016/j.optlastec.2018.06.061.
- [36]. Trifa, A., A. Hedhili, and W. L. Chaari, "Knowledge tracing with an intelligent agent, in an E-learning platform," *Educ. Inf. Technol.*, vol. 24, no. 1, pp. 711–741, Jan. 2019, doi: 10.1007/s10639-018-9792-5.
- [37]. V. Bendre, Y. Patil, Y. Kadam, and P. Hupare, "TIMIR (Low Light - Dark Images)," *Mendeley Data*, Jul. 2024, doi: 10.17632/3jhhtc57t5.1.
- [38]. Wang, Q. and R. K. Tan, "Fast image/video contrast enhancement based on weighted thresholded histogram equalization," *IEEE Trans. Consum. Electron.*, vol. 53, no. 2, pp. 757–764, May 2007, doi: 10.1109/TCE.2007.381756.
- [39]. Wang, X. and L. Chen, "An effective histogram modification scheme for image contrast enhancement," *Signal Process., Image Commun.*, vol. 58, pp. 187–198, Oct. 2017, doi: 10.1016/j.image.2017.07.009.

- [40]. Wilensky, U. and W. Rand, An Introduction to Agent-Based Modeling With NetLogo. Cambridge, MA, USA: MIT Press, 2015.
- [41]. Wooldridge, M. and N. R. Jennings, "Intelligent agents: Theory and practice," Knowl. Eng. Rev., vol. 10, no. 2, pp. 115–152, Jun. 1995.
- [42]. Wu, H., S. Tang, J. Huang, and Y. Shi, "A novel reversible data hiding method with image contrast enhancement," Signal Process., Image Commun., vol. 62, pp. 64–73, Mar. 2018, doi: 10.1016/j.image.2017.12.006.
- [43]. Wu, W. et al., "Information entropy-based strategy for the quantitative evaluation of extensive hyperspectral images to better unveil spatial heterogeneity in mass spectrometry imaging," Anal. Chem., vol. 94, no. 29, pp. 10355–10366, Nov. 2022.
- [44]. Zhao, C. et al., "A new approach for medical image enhancement based on luminance-level modulation and gradient modulation," Biomed. Signal Process. Control, vol. 48, pp. 189–196, Feb. 2019, doi: 10.1016/j.bspc.2018.10.008.



**Jorge Rafael Del Ángel Mercado**  
Estudiante de ingeniería en Computación en CUCEI desde el 2022, con especialidad en Inteligencia Artificial y Redes de Computadoras.




**Emmanuel Alejandro Barba Lugo**  
Estudiante de ingeniería en Computación en CUCEI desde el 2021, con especialidad Redes de computadoras e Inteligencia Artificial.



**Luis Fernando Monjaraz Briseño**  
Estudiante de ingeniería en Computación en CUCEI desde el 2021, con especialidad en Videojuegos e Inteligencia Artificial.



**Eduardo de Jesús Quintero Meza**  
Estudiante de Ingeniería en Computación en CUCEI desde el 2021, con especialidad en Inteligencia Artificial y Diseño de Videojuegos.



**Teresa Dávila Godínez** Estudiante de ingeniería en Computación en CUCEI desde el 2022, con especialidad en Inteligencia Artificial.